

UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Facultad de Ingeniería de Sistemas e Informática

Escuela Profesional de Ingeniería de Software

Solución integral de Inteligencia de Negocios para una empresa retail ficticia

Repositorio: <https://github.com/KarloToro/Business-Intelligence-Final-Proyect.git>

Asignatura: Inteligencia de Negocios

Docente: Mg. Juan Gamarra Moreno

Semestre: 2026-1

Grupo 7

- Karlo Toro: Generación de datos
- Hector Huapaya: Científico de datos
 - Leslie Diaz: Arquitecto de BI
- Alex Palomino: Analista de negocio

Lima, Perú – 2026

Índice

1. Resumen ejecutivo del proyecto y principales hallazgos	4
1.1. Indicadores clave	4
1.2. Principales hallazgos.....	4
2. Descripción de la empresa ficticia, problemática y preguntas de negocio	6
2.1. Empresa ficticia	6
2.2. Problemática	6
2.3. Objetivo general	7
2.4. Objetivos específicos	7
2.5. Preguntas de negocio.....	7
3. Generación de datos sintéticos: esquema, volúmenes, distribuciones y problemas de calidad	8
3.1. Alcance de los datos	8
3.2. Esquema de datos y volúmenes.....	8
3.3. Reglas de realismo.....	9
3.4. Problemas de calidad introducidos	9
3.5. Validación de calidad	10
4. Parte 1 - Datamart: modelo dimensional, ETL, diccionario y modelo en Power BI ..	10
4.1. Modelo dimensional	10
4.2. Relaciones del modelo	11
4.3. Proceso ETL y validación	11
4.4. Evidencias de la Parte 1	12
5. Parte 2 - Visualización: tablero, medidas DAX e insights	13
5.1. Tablero Power BI.....	13
5.2. Medidas DAX principales	16
5.3. Visualización en Python	16
5.4. Insights accionables	19
5.5. Evidencias de la Parte 2.....	19
6. Parte 3 - Clasificación: definición, modelos, evaluación e interpretación	20
6.1. Definición del problema	20
6.2. Feature engineering	20
6.3. Modelos y evaluación	20
6.4. Resultado exportado	21
6.5. Integración con Power BI	21
6.6. Interpretación de negocio	22
6.7. Evidencias de la Parte 3.....	22
7. Parte 4 - Segmentación: RFM, clusters, perfiles y estrategias	23
7.1. Método	23
7.2. Segmentos identificados	23
7.3. Estrategias diferenciadas	24
7.4. Integración con Power BI	24
7.5. Evidencias de la Parte 4.....	24
8. Parte 5 - Asociación: reglas y propuestas de venta cruzada.....	25
8.1. Método	25
8.2. Resultados	25

8.3. Integración con Power BI	26
8.4. Propuesta de negocio.....	26
8.5. Evidencias de la Parte 5.....	27
9. Parte 6 - Regresión: pronóstico, métricas y recomendaciones.....	27
9.1. Objetivo	27
9.2. Variables predictoras.....	27
9.3. Comparativa de modelos.....	28
9.4. Integración con Power BI	28
9.5. Recomendación de negocio	29
9.6. Evidencias de la Parte 6.....	29
10. Reflexión ética e integridad; anexo de prompts	30
10.1. Reflexión ética.....	30
10.2. Integridad académica y uso de IA.....	30
10.3. Anexo de prompts y evidencias.....	30
10.4. Bitácora	31
11. Conclusiones, recomendaciones y tabla de contribución por integrante	31
11.1. Conclusiones.....	31
11.2. Recomendaciones.....	32
11.3. Tabla de contribución	33
11.4. Autoevaluación por componente	33

1. Resumen ejecutivo del proyecto y principales hallazgos

El proyecto desarrolla una solución integral de Inteligencia de Negocios para AndesMarket S.A.C., una empresa retail ficticia de operación omnicanal. La solución está orientada a convertir datos transaccionales sintéticos en información accionable para la toma de decisiones gerenciales. Se integran seis componentes: generación de datos, datamart analítico, visualización en Power BI, clasificación de abandono, segmentación de clientes, análisis de canasta de mercado y pronóstico de ventas.

La base de trabajo contiene 5,000 clientes sintéticos, 506 productos, 15 tiendas o canales, 29 promociones, 34,755 tickets y 55,858 líneas de venta para el periodo 2024-2025. La validación del datamart confirma consistencia en claves foráneas, fechas, promociones vigentes, canastas y métricas derivadas.

1.1. Indicadores clave

Indicador	Resultado
Ventas totales	S/ 1,428,828.50
Ganancia total	S/ 392,905.10
Tickets de venta	34,755
Líneas de venta	55,858
Clientes con venta	5,000
Productos vendidos	506

1.2. Principales hallazgos

- Los productos estrella generan S/ 762,080.07 en ingresos, superando a los productos no estrella.
- El segmento Bronce aporta el mayor ingreso total dentro del programa de fidelización.

- El modelo de clasificación de abandono identifica 810 clientes en riesgo alto y 505 en riesgo medio, permitiendo priorizar campañas de retención.
- La segmentación RFM agrupa a los 5,000 clientes en cuatro perfiles comerciales diferenciados, con estrategias específicas para cada uno.
- El análisis de asociación genera 26 reglas de canasta de mercado; la regla con mayor lift (4.252) relaciona Bebidas + Lácteos con Snacks y Dulces.
- El modelo de regresión con Gradient Boosting alcanza un MAPE de 13.69%, útil como referencia de planificación operativa.
- La documentación incluye el registro de prompts y las dependencias de Python para favorecer la trazabilidad, reproducibilidad y revisión técnica.

El siguiente tablero resume de forma visual los indicadores principales:




Figura 1. Resumen ejecutivo - Tablero Power BI

2. Descripción de la empresa ficticia, problemática y preguntas de negocio

2.1. Empresa ficticia

La empresa analizada es AndesMarket S.A.C., una cadena retail ficticia de operación omnicanal, con tiendas físicas y canal online en distintas regiones del Perú. Comercializa productos de consumo masivo y categorías complementarias como abarrotes, bebidas, lácteos, frutas y verduras, carnes y aves, limpieza, cuidado personal, hogar, bebés, mascotas, congelados, snacks y dulces.

La empresa cuenta con un programa de fidelización (AndesPlus) que identifica a sus clientes recurrentes en distintos segmentos: Bronce, Plata, Oro y Platino.

2.2. Problemática

La gerencia necesita pasar de datos operativos dispersos a una solución analítica que permita:

- Monitorear ventas, margen y rentabilidad por período, categoría y canal.
- Evaluar el rendimiento de productos, categorías, tiendas y canales.
- Identificar clientes en riesgo de abandono del programa de fidelización.
- Segmentar clientes para diseñar campañas diferenciadas.
- Detectar oportunidades de venta cruzada entre categorías.
- Pronosticar ventas para apoyar la planificación de inventario y campañas.

Actualmente la información está dispersa en archivos operativos con inconsistencias, y no existe un repositorio analítico único ni tableros confiables. Las decisiones se toman de forma intuitiva.

2.3. Objetivo general

Diseñar, construir y sustentar una solución integral de Inteligencia de Negocios para una empresa retail ficticia, que abarque desde el datamart analítico hasta los modelos de minería de datos (clasificación, segmentación, asociación y regresión), generando información accionable para la toma de decisiones gerenciales.

2.4. Objetivos específicos

Objetivos específicos:

- Diseñar e implementar un datamart con enfoque multidimensional y un proceso ETL reproducible en Python.
- Construir tableros de visualización en Power BI con medidas DAX que respondan preguntas de negocio.
- Desarrollar y evaluar modelos de clasificación, segmentación, asociación y regresión sobre el datamart.
- Generar y documentar datos sintéticos realistas, con problemas de calidad controlados, y los prompts utilizados.
- Comunicar hallazgos con rigor técnico y sentido de negocio, demostrando dominio individual y trabajo colaborativo.

2.5. Preguntas de negocio

Pregunta	Técnica asociada
¿Cómo evolucionan las ventas y el margen por periodo, categoría, tienda y canal?	Visualización (Partes 1 y 2)
¿Qué clientes presentan mayor probabilidad de abandono?	Clasificación (Parte 3)
¿Qué segmentos de clientes existen y qué estrategia corresponde a cada uno?	Segmentación RFM + K-Means (Parte 4)
¿Qué categorías se compran juntas y qué promociones cruzadas conviene impulsar?	Asociación FP-Growth (Parte 5)
¿Cuál es la venta esperada para apoyar la planificación de inventario y campañas?	Regresión (Parte 6)

3. Generación de datos sintéticos: esquema, volúmenes, distribuciones y problemas de calidad

3.1. Alcance de los datos

Los datos son sintéticos y fueron generados con fines académicos mediante Python (pandas, numpy y faker) con semilla fija (42) para garantizar reproducibilidad. No contienen información real de personas ni empresas.

El repositorio conserva los datos de entrada en data/raw/; sobre estos se introducen problemas de calidad controlados, y el proceso ETL genera las tablas depuradas y listas para análisis en data/processed/.

3.2. Esquema de datos y volúmenes

Tabla	Filas	Campos principales	Uso principal
dim_cliente.csv	5,000	id_cliente, nombre, sexo, fecha_nacimiento, distrito, fecha_alta, segmento_programa	Perfil de clientes
dim_producto.csv	506	id_producto, nombre, categoria, subcategoria, marca, precio_lista, costo	Catálogo de productos
dim_tienda.csv	15	id_tienda, nombre, canal, region, ciudad	Tiendas y canales
dim_promocion.csv	29	id_promocion, nombre, tipo, descuento_pct, fecha_inicio, fecha_fin	Campañas y descuentos
dim_tiempo.csv	731	fecha, dia, mes, trimestre, anio, dia_semana, es_feriado	Calendario 2024-2025
fact_ventas.csv	55,858	id_venta, fecha, id_cliente, id_producto, id_tienda, id_promocion, cantidad, precio_unitario, descuento	Líneas de venta

3.3. Reglas de realismo

La generación considera reglas de negocio orientadas a simular una operación retail verosímil:

- **Cobertura completa:** todos los clientes realizan al menos una compra.
- **Probabilidad por segmento:** los segmentos superiores (Oro, Platino) tienen mayor probabilidad de recompra.
- **Coherencia geográfica:** las tiendas se asignan dentro de la región del cliente.
- **Productos estrella:** una parte del catálogo se identifica como producto estrella con mayor rotación.
- **Vigencia de promociones:** las promociones solo aplican dentro de su periodo de vigencia.
- **Tickets multi-línea:** los tickets pueden contener múltiples líneas de venta.
- **Afinidad de canasta:** existen asociaciones entre categorías para que el análisis de asociación genere reglas con lift > 1.
- **Estacionalidad:** mayor volumen en julio (Fiestas Patrias) y diciembre (Navidad).
- **Concentración Pareto:** ~20% de productos concentran el 80% de las ventas.

3.4. Problemas de calidad introducidos

Los datos crudos (data/raw/) contienen, de manera controlada, los siguientes problemas:

Problema de calidad	Descripción	Tratamiento en ETL
Fechas en formatos mixtos	Mezcla de dd/mm/aaaa, aaaa-mm-dd y texto	Parseo robusto y estandarización
Valores faltantes	Nulos en descuento, distrito, categoría (~3-8%)	Imputación o reglas de negocio

Duplicados	~1-2% de líneas de venta repetidas	Eliminación por clave de negocio
Texto inconsistente	Categorías en mayúsculas/minúsculas y con espacios	Normalización (trim, mapeo)
Errores de tipeo	Variantes como Lacteos, lacteos, LÁCTEOS	Diccionario de homologación
Outliers	Cantidades o precios extremos poco realistas	Detección y recorte
Claves huérfanas	~0.5% de id_producto inexistente en dim_producto	Validación de integridad referencial

3.5. Validación de calidad

El notebook notebooks/01_datamart_etl.ipynb y el script scripts/validar_dataset.py validan la versión procesada del dataset. Los resultados confirman claves foráneas consistentes, fechas válidas, promociones dentro de vigencia y métricas derivadas correctamente calculadas.

4. Parte 1 - Datamart: modelo dimensional, ETL, diccionario y modelo en Power BI

4.1. Modelo dimensional

El datamart sigue un esquema estrella con fact_ventas como tabla central y cinco dimensiones: cliente, producto, tienda, promoción y tiempo. El grano de la tabla de hechos es la línea individual de venta (id_venta + numero_linea): cada fila representa un producto dentro de un ticket de venta.

La siguiente captura muestra el modelo de relaciones implementado en Power BI:




Figura 2. Modelo de relaciones - Esquema estrella del datamart

4.2. Relaciones del modelo

Relación	Tipo	Cardinalidad
fact_ventas.id_cliente -> dim_cliente.id_cliente	Muchos a uno	N:1
fact_ventas.id_producto -> dim_producto.id_producto	Muchos a uno	N:1
fact_ventas.id_tienda -> dim_tienda.id_tienda	Muchos a uno	N:1
fact_ventas.id_promocion -> dim_promocion.id_promocion	Muchos a uno	N:1
fact_ventas.fecha -> dim_tiempo.fecha	Muchos a uno	N:1

4.3. Proceso ETL y validación

El notebook notebooks/01_datamart_etl.ipynb documenta la carga, transformación, validación y exportación de las tablas listas para Power BI. El proceso ETL realiza:

- Carga de datos crudos desde data/raw/ con reporte de métricas de calidad iniciales.

- **Estandarización de fechas:** parseo robusto de formatos mixtos a tipo fecha.
- **Normalización de texto:** trim, mapeo de categorías y homologación de tipesos.
- Eliminación de duplicados por clave de negocio (id_venta + id_producto).
- **Tratamiento de nulos:** imputación con reglas de negocio justificadas (descuento = 0 cuando no hay promoción).
- **Validación de integridad referencial:** eliminación de claves huérfanas.
- **Derivación de métricas:** cálculo de $\text{importe_venta} = \text{cantidad} \times \text{precio_unitario} \times (1 - \text{descuento})$ y $\text{margen} = \text{importe} - \text{costo}$.
- Exportación de tablas limpias a data/processed/ y generación del diccionario de datos.

La validación final confirma:

- Claves foráneas sin huérfanos.
- Fechas estandarizadas y dentro del rango 2024-2025.
- Promociones aplicadas solo dentro de su vigencia.
- Métricas importe_venta y margen consistentes.
- Diccionario de datos generado en docs/diccionario_datos.md.

4.4. Evidencias de la Parte 1

Evidencia	Ruta
Notebook ETL	notebooks/01_datamart_etl.ipynb
Diccionario de datos	docs/diccionario_datos.md
Modelo Power BI	powerbi/RetailBI.pbix
Captura del modelo de relaciones	informe/img/modelo_relaciones.png
Datos procesados	data/processed/*.csv

5. Parte 2 - Visualización: tablero, medidas DAX e insights

5.1. Tablero Power BI

El archivo principal de visualización es powerbi/RetailBI.pbix. El tablero contiene 8 páginas que cubren desde el resumen ejecutivo hasta las páginas analíticas de clasificación, segmentación, asociación y pronóstico.

Página 1: Resumen ejecutivo

El resumen ejecutivo presenta los KPIs principales de AndesMarket: ventas totales (S/ 1,428,828.50), ganancia total (S/ 392,905.10), 34,755 tickets y 5,000 clientes. Incluye desglose por período, canal y segmento de programa.




Figura 3. Página 1 - Resumen ejecutivo

Página 2: Análisis por categoría

El análisis por categoría permite identificar las categorías líderes en ventas e ingresos, la participación de productos estrella (S/ 762,080) frente a productos regulares, y el mix comercial del catálogo.




Figura 4. Página 2 - Análisis por categoría de producto

Página 3: Análisis por tienda y canal

La vista de tiendas/canales muestra el rendimiento comparativo entre tiendas físicas y el canal online, permitiendo identificar las tiendas con mayor y menor contribución al margen.




Figura 5. Página 3 - Análisis por tienda y canal

Página 4: Tendencia temporal

La vista de tendencia temporal presenta la evolución de ventas, margen y ticket promedio a lo largo del periodo 2024-2025, evidenciando patrones de estacionalidad.




Figura 6. Página 4 - Tendencia temporal de ventas

5.2. Medidas DAX principales

Las siguientes medidas DAX fueron implementadas en el modelo Power BI:

Medida	Fórmula DAX
Ventas Totales	SUMX(Fact_Ventas, Fact_Ventas[Cantidad] * Fact_Ventas[PrecioUnitario] * (1 - Fact_Ventas[Descuento]))
Margen Bruto	[Ventas Totales] - SUMX(Fact_Ventas, Fact_Ventas[Cantidad] * RELATED(Dim_Producto[Costo]))
Ticket Promedio	DIVIDE([Ventas Totales], DISTINCTCOUNT(Fact_Ventas[IdVenta]))
Ventas Mes Anterior	CALCULATE([Ventas Totales], DATEADD(Dim_Tiempo[Fecha], -1, MONTH))
Crecimiento %	DIVIDE([Ventas Totales] - [Ventas Mes Anterior], [Ventas Mes Anterior])

5.3. Visualización en Python

El notebook notebooks/02_visualizacion.ipynb genera visualizaciones complementarias con matplotlib y seaborn, que sirven como análisis exploratorio previo y como respaldo gráfico del informe.

Evolución mensual de ventas

La serie temporal muestra los patrones de estacionalidad durante el periodo 2024-2025, con picos esperados en meses de alta demanda y valles en periodos de menor actividad.




Figura 7. Evolución mensual de ventas - AndesMarket

Ventas por categoría

El gráfico de barras desglosa los ingresos por categoría, permitiendo identificar las categorías líderes que definen el mix comercial principal de la empresa.




Figura 8. Ventas por categoría de producto

Pareto de productos

El análisis de Pareto confirma la concentración de ingresos: un subconjunto reducido de productos (~20%) concentra la mayor parte de las ventas, siguiendo el principio 80/20.




Figura 9. Análisis de Pareto de productos

Mapa de calor: mes x categoría

El heatmap permite visualizar qué categorías tienen mayor demanda en cada mes, identificando patrones cruzados de estacionalidad y preferencia por categoría.




Figura 10. Mapa de calor - Ventas por mes y categoría

5.4. Insights accionables

A partir del tablero Power BI y las visualizaciones en Python, se identifican los siguientes insights:

- **Estacionalidad:** las ventas muestran patrones temporales claros durante 2024-2025, con picos que pueden aprovecharse para campañas estacionales.
- **Concentración Pareto:** un subconjunto reducido de productos concentra la mayor parte de los ingresos, lo que sugiere priorizar su disponibilidad y visibilidad.
- **Productos estrella:** los productos estrella generan S/ 762,080 en ingresos, lo que confirma su importancia estratégica.
- **Diferencias por canal:** existen diferencias significativas de contribución entre canal físico y online, con oportunidades de crecimiento en el canal digital.
- **Segmento Bronce:** este segmento aporta el mayor ingreso total, lo que sugiere estrategias de ascenso hacia segmentos superiores.
- **Mix de categorías:** las categorías líderes definen el mix comercial principal y deben mantenerse bien abastecidas.

5.5. Evidencias de la Parte 2

Evidencia	Ruta
Tablero Power BI (8 páginas)	powerbi/RetailBI.pbix
Notebook de visualización	notebooks/02_visualizacion.ipynb
Capturas del tablero	informe/img/pag01_resumen.png a pag08_pronostico.png
Gráficos Python	informe/img/ventas_mensuales.png, ventas_por_categoria.png, pareto_productos.png, heatmap_mes_categoria.png

6. Parte 3 - Clasificación: definición, modelos, evaluación e interpretación

6.1. Definición del problema

El objetivo de la clasificación es identificar clientes con riesgo de abandono del programa de fidelización, a partir de variables derivadas del comportamiento transaccional. Un cliente se considera en abandono si no registra compras en los últimos N meses del periodo analizado.

El notebook principal es notebooks/03_clasificacion.ipynb.

6.2. Feature engineering

La tabla analítica se construye a partir del datamart con las siguientes variables derivadas por cliente:

- **Antigüedad:** meses desde la fecha de alta.
- **Recencia:** días desde la última compra.
- **Frecuencia:** número de transacciones realizadas.
- **Monto acumulado:** total de importe generado.
- **Categorías compradas:** diversidad del mix de compra.
- **Uso de promociones:** proporción de compras con descuento.

La división en entrenamiento y prueba se realiza de forma estratificada (75/25) con semilla 42.

6.3. Modelos y evaluación

Se entrenaron y compararon tres modelos de clasificación supervisada:

Modelo	Accuracy	Recall abandono	ROC-AUC
Regresión Logística (*)	0.75	0.77	0.828
Árbol de Decisión	0.74	0.72	0.815
Random Forest	0.79	0.41	0.806

(*) *Modelo seleccionado: Regresión Logística. Aunque Random Forest tiene mayor accuracy (0.79), la Regresión Logística presenta mejor recall para la clase de abandono (0.77 vs 0.41) y mejor ROC-AUC (0.828 vs 0.806). Para un problema donde el costo de no detectar un cliente en riesgo es alto, priorizar el recall es la decisión correcta.*

6.4. Resultado exportado

El archivo data/processed/predicciones_abandono.csv contiene las predicciones para los 5,000 clientes:

Riesgo	Clientes	Acción sugerida
Alto	810	Contacto directo, descuentos personalizados, llamada de retención
Medio	505	Campañas preventivas, ofertas por segmento, comunicación proactiva
Bajo	3,000	Mantenimiento del vínculo, programa regular de fidelización
Sin etiqueta	685	Revisión manual o asignación por regla de negocio

6.5. Integración con Power BI

Las predicciones de riesgo se integran al tablero Power BI en una página específica de Riesgo de abandono, que permite segmentar por nivel de riesgo y visualizar el valor monetario de los clientes en cada categoría.



Figura 11. Página 5 - Dashboard de riesgo de abandono

6.6. Interpretación de negocio

El modelo permite priorizar las campañas de retención. Los 810 clientes en riesgo alto representan una oportunidad de retención directa; los 505 en riesgo medio pueden incluirse en campañas preventivas antes de que escalen a riesgo alto. La importancia de variables indica que la recencia y la frecuencia de compra son los factores más determinantes del abandono.

6.7. Evidencias de la Parte 3

Evidencia	Ruta
Notebook de clasificación	notebooks/03_clasificacion.ipynb
Predicciones exportadas	data/processed/predicciones_abandono.csv
Página Power BI de abandono	informe/img/pag05_abandono.png

7. Parte 4 - Segmentación: RFM, clusters, perfiles y estrategias

7.1. Método

El notebook notebooks/04_segmentacion.ipynb implementa la segmentación de clientes mediante el enfoque RFM + K-Means:

- Cálculo de variables RFM por cliente: Recencia, Frecuencia y Monto.
- Estandarización de las variables para que ninguna domine por su magnitud.
- Determinación del número de clusters mediante el método del codo y el coeficiente de silueta.
- Aplicación de K-Means con k=4 y semilla fija (42).
- Perfilamiento de cada segmento (tamaño, RFM promedio, categorías preferidas, ticket).
- Exportación de la asignación cliente-segmento a data/processed/segmentos_clientes.csv.

7.2. Segmentos identificados

Segmento	Clientes	% del total	Perfil
Leales / Frecuentes	2,206	44.1%	Alta frecuencia, monto intermedio, compras recientes
Campeones / VIP	1,537	30.7%	Alta frecuencia, alto monto, compras muy recientes
Nuevos / Esporádicos	690	13.8%	Baja frecuencia, bajo monto, incorporación reciente
En Riesgo / Inactivos	567	11.3%	Baja frecuencia, alta recencia, inactividad prolongada

7.3. Estrategias diferenciadas

Segmento	Estrategia propuesta
Campeones / VIP	Beneficios exclusivos, acceso anticipado a promociones, atención preferencial y fidelización premium.
Leales / Frecuentes	Promociones recurrentes, campañas de acumulación de puntos y estímulo para ascenso a VIP.
Nuevos / Esporádicos	Incentivos de segunda compra, descuentos de bienvenida y comunicación de valor del programa.
En Riesgo / Inactivos	Campañas de recuperación activa, ofertas personalizadas por historial y contacto directo.

7.4. Integración con Power BI

La asignación de segmentos se importa al modelo Power BI, donde se crea una página específica de Segmentación de clientes que muestra el tamaño de cada segmento, su aporte a las ventas y su perfil RFM promedio.




Figura 12. Página 6 - Dashboard de segmentación de clientes

7.5. Evidencias de la Parte 4

Evidencia	Ruta
-----------	------

Notebook de segmentación	notebooks/04_segmentacion.ipynb
Segmentos exportados	data/processed/segmentos_clientes.csv
Página Power BI de segmentación	informe/img/pag06_segmentacion.png

8. Parte 5 - Asociación: reglas y propuestas de venta cruzada

8.1. Método

El notebook notebooks/05_asociacion.ipynb aplica FP-Growth sobre las transacciones agrupadas por boleta (id_venta). El análisis se realiza a nivel de categoría de producto para obtener reglas más estratégicas y accionables.

El proceso consiste en:

- Preparar las transacciones: agrupar los productos de cada boleta en formato de canasta.
- Codificar a matriz booleana (one-hot por categoría).
- Aplicar FP-Growth con soporte mínimo razonable para obtener itemsets frecuentes.
- Generar reglas de asociación con cálculo de soporte, confianza y lift.
- Filtrar reglas relevantes con lift > 1 y confianza significativa.

8.2. Resultados

El archivo data/processed/reglas_asociacion.csv contiene 26 reglas de asociación con métricas de soporte, confianza y lift.

Regla destacada:

Antecedente	Consecuente	Soporte	Confianza	Lift
-------------	-------------	---------	-----------	------

Bebidas + Lácteos	Snacks y Dulces	0.012	0.454	4.252
-------------------	-----------------	-------	-------	-------

Un lift de 4.252 indica que los clientes que compran Bebidas y Lácteos tienen 4.25 veces más probabilidad de comprar Snacks y Dulces que un cliente promedio.

8.3. Integración con Power BI

Las reglas de asociación se importan al modelo Power BI en una página específica de Canasta de mercado que permite explorar las reglas por categoría, filtrar por nivel de lift y visualizar las oportunidades de venta cruzada.



Figura 13. Página 7 - Dashboard de canasta de mercado

8.4. Propuesta de negocio

Las 26 reglas generadas permiten diseñar acciones concretas de venta cruzada:

- Combos y paquetes promocionales entre categorías con alta afinidad (ej. Bebidas + Snacks).

- Recomendaciones digitales en el canal online basadas en el historial de compra del cliente.
- **Exhibición conjunta en tiendas físicas:** colocar productos relacionados en zonas adyacentes.
- **Campañas cruzadas por temporada:** aprovechar los meses de mayor demanda para impulsar combos de categorías asociadas.

8.5. Evidencias de la Parte 5

Evidencia	Ruta
Notebook de asociación	notebooks/05_asociacion.ipynb
Reglas de asociación exportadas	data/processed/reglas_asociacion.csv
Página Power BI de canasta	informe/img/pag07_canasta.png

9. Parte 6 - Regresión: pronóstico, métricas y recomendaciones

9.1. Objetivo

El notebook notebooks/06_regresion.ipynb pronostica las ventas diarias agregadas para apoyar decisiones de inventario, campañas y planificación operativa. El resultado se exporta a data/processed/pronostico_ventas.csv con valores reales vs. pronosticados.

9.2. Variables predictoras

Las variables de entrada incluyen:

- **Componentes temporales:** día de la semana, mes, trimestre, indicador de feriado.
- **Estacionalidad:** codificación cíclica de mes y día de la semana.
- **Indicador de promoción:** si hay promociones activas en la fecha.

- **Rezagos (lags):** ventas de los últimos 7 y 30 días como predictores.

La división de datos respeta el orden temporal: se entrena con el 80% más antiguo y se valida con el 20% más reciente.

9.3. Comparativa de modelos

Se entrenaron y compararon tres modelos de regresión:

Modelo	MAE	RMSE	MAPE	R2
Regresión Lineal	S/ 298.73	S/ 373.93	15.94%	0.168
Random Forest	S/ 278.20	S/ 350.42	14.35%	0.270
Gradient Boosting (*)	S/ 265.15	S/ 340.15	13.69%	0.312

() Modelo seleccionado: Gradient Boosting. Presenta el mejor desempeño en todas las métricas. El MAPE de 13.69% indica que, en promedio, el pronóstico se desvía un 13.69% del valor real, lo cual es una referencia operativa útil para planificación.*

9.4. Integración con Power BI

La tabla de real vs. pronóstico se importa al modelo Power BI en una página específica de Pronóstico de demanda que muestra la curva real frente a la pronosticada y el MAPE como KPI.




Figura 14. Página 8 - Dashboard de pronóstico de ventas

9.5. Recomendación de negocio

- El pronóstico con Gradient Boosting puede usarse como referencia operativa para la planificación de inventario y campañas.
- El R2 de 0.312 indica que todavía hay espacio para mejorar las variables predictoras (incorporar datos de tráfico, clima, eventos, etc.).
- Se recomienda complementar el pronóstico con el criterio comercial del equipo de ventas para ajustar decisiones finales.
- Actualizar el modelo periódicamente con datos más recientes para mantener su relevancia.

9.6. Evidencias de la Parte 6

Evidencia	Ruta
Notebook de regresión	notebooks/06_regresion.ipynb
Pronóstico exportado	data/processed/pronostico_ventas.csv
Página Power BI de pronóstico	informe/img/pag08_pronostico.png

10. Reflexión ética e integridad; anexo de prompts

10.1. Reflexión ética

El proyecto utiliza datos sintéticos, lo cual reduce significativamente los riesgos de exposición de información personal real. Esta decisión es adecuada para el contexto académico, porque permite practicar generación de datos, ETL, modelado BI y minería de datos sin comprometer la privacidad de personas reales.

Sin embargo, es importante considerar las siguientes implicaciones éticas:

- **Sesgos en datos sintéticos:** las reglas de generación pueden introducir sesgos que no reflejan el comportamiento real del mercado.
- **Riesgos del modelo de clasificación:** un falso negativo podría dejar sin atención a un cliente riesgoso; un falso positivo podría dirigir esfuerzos comerciales innecesarios.
- **Nombres de segmentos:** asignar etiquetas comerciales a clusters estadísticos requiere validación humana para evitar estrategias equivocadas.
- **Limitaciones del pronóstico:** utilizar un modelo con R^2 bajo como única base para decisiones de inventario podría generar sobre-stock o desabastecimiento.

10.2. Integridad académica y uso de IA

El uso de herramientas de IA fue documentado en `prompts/registro_prompts.md`. El equipo puede explicar el código, las métricas y las decisiones tomadas en cada parte del proyecto. Los resultados generados por asistentes de IA fueron verificados, ajustados y comprendidos por el equipo antes de incorporarlos a la solución.

10.3. Anexo de prompts y evidencias

Repositorio principal: <https://github.com/KarloToro/Business-Intelligence-Final-Proyect.git>

Evidencia	Ruta local
README	README.md
Dependencias Python	requirements.txt
Diccionario de datos	docs/diccionario_datos.md
Registro de prompts	prompts/registro_prompts.md
Generación de datos	notebooks/00_generacion_datos.ipynb
Datamart ETL	notebooks/01_datamart_etl.ipynb
Visualización Python	notebooks/02_visualizacion.ipynb
Clasificación	notebooks/03_clasificacion.ipynb
Segmentación	notebooks/04_segmentacion.ipynb
Asociación	notebooks/05_asociacion.ipynb
Regresión	notebooks/06_regresion.ipynb
Power BI	powerbi/RetailBI.pbix

10.4. Bitácora

La bitácora de trabajo colaborativo se gestiona en un Excel compartido del equipo, con registro de fecha, integrante, actividad realizada y tiempo dedicado. La bitácora es evidencia del trabajo colaborativo y forma parte de la rúbrica transversal. El link de la bitácora es el siguiente: https://docs.google.com/spreadsheets/d/1ews_TxKJ-6ncAKyb7dUoiCyXqb1N7-79waDI4JjyLq/edit?usp=sharing

11. Conclusiones, recomendaciones y tabla de contribución por integrante

11.1. Conclusiones

- El proyecto integra datos sintéticos, datamart analítico, tablero Power BI y cuatro modelos de minería de datos en una solución BI coherente y reproducible.
- El datamart sigue un esquema estrella con cinco dimensiones y una tabla de hechos, con validaciones de integridad que garantizan la consistencia de los datos procesados.
- El tablero Power BI (8 páginas) permite comunicar resultados a nivel ejecutivo, con interactividad mediante segmentadores y filtros.

- La clasificación de abandono (Regresión Logística, ROC-AUC = 0.828) identifica 1,315 clientes en riesgo alto y medio, habilitando campañas de retención diferenciadas.
- La segmentación RFM + K-Means agrupa a los clientes en cuatro perfiles con estrategias comerciales específicas para cada uno.
- El análisis de asociación (FP-Growth) genera 26 reglas de canasta con oportunidades concretas de venta cruzada, destacando la regla Bebidas + Lácteos -> Snacks y Dulces (lift = 4.252).
- El pronóstico con Gradient Boosting (MAPE = 13.69%) es una referencia operativa útil para planificación, con margen de mejora en variables predictoras.
- Los resultados deben interpretarse dentro del escenario sintético y no como evidencia de un mercado real.

11.2. Recomendaciones

- **Retención:** consolidar campañas de retención para los 810 clientes en riesgo alto y 505 en riesgo medio, con acciones diferenciadas por nivel.
- **Productos estrella:** mantener vigilancia permanente sobre los productos estrella por su impacto desproporcionado en ingresos (S/ 762,080).
- **Segmentación:** usar los cuatro segmentos RFM para diseñar estrategias diferenciadas: fidelización VIP, estímulo a frecuentes, captación de esporádicos y recuperación de inactivos.
- **Venta cruzada:** aplicar las 26 reglas de asociación en combos, exhibición conjunta, recomendaciones digitales y campañas por temporada.
- **Pronóstico:** utilizar el modelo de Gradient Boosting como referencia de planificación operativa, complementándolo con criterio comercial.

- **Mejora continua:** incorporar más variables predictoras al modelo de regresión y actualizar periódicamente los modelos con datos recientes.

11.3. Tabla de contribución

Integrante	Rol	Actividades principales	Porcentaje
Karlo Toro	Generación de datos	Datos sintéticos, scripts, reglas de generación, validación inicial y soporte de tablas maestras.	25%
Hector Huapaya	Científico de datos	Clasificación, segmentación, asociación, regresión, métricas y exportaciones analíticas para Power BI.	25%
Leslie Diaz	Arquitecto de BI	Datamart, diccionario, Power BI, modelo de relaciones, tablero ejecutivo y visualización.	25%
Alex Palomino	Analista de negocio / editor	Contexto de negocio, interpretación, insights, recomendaciones, ética, prompts e informe consolidado.	25%

Los porcentajes reflejan una distribución equitativa del trabajo por rol. Todos los integrantes participaron en el análisis y comprenden la totalidad de la solución.

11.4. Autoevaluación por componente

Componente	Punt. máx.	Peso en PG	Autopuntaje (0–20)	Evidencia (archivo / sección)
Parte 1 — Datamart	20	20%	19	Sección 4 del informe; notebooks/01_datamart_etl.ipynb; docs/diccionario_datos.md; data/processed/fact_ventas.csv; informe/img/modelo_relaciones.png; powerbi/RetailBI.pbix.

Parte 2 — Visualización	20	15%	19	Sección 5 del informe; notebooks/02_visualizacion.ipynb; powerbi/RetailBI.pbix; páginas 1–4 del tablero; capturas pag01_resumen.png a pag04_tendencia.png; gráficos de Python en informe/img/.
Parte 3 — Clasificación	20	16%	18	Sección 6 del informe; notebooks/03_clasificacion.ipynb; comparación de Regresión Logística, Árbol de Decisión y Random Forest; data/processed/predicciones_abandono.csv; informe/img/pag05_abandono.png.
Parte 4 — Segmentación	20	16%	19	Sección 7 del informe; notebooks/04_segmentacion.ipynb; aplicación de RFM y K-Means con cuatro segmentos; data/processed/segmentos_clientes.csv; informe/img/pag06_segmentacion.png.
Parte 5 — Asociación	20	16%	19	Sección 8 del informe; notebooks/05_asociacion.ipynb; aplicación de FP-Growth; 26 reglas con soporte, confianza y lift; data/processed/reglas_asociacion.csv; informe/img/pag07_canasta.png.
Parte 6 — Regresión	20	17%	18	Sección 9 del informe; notebooks/06_regresion.ipynb; comparación de Regresión Lineal, Random Forest y Gradient Boosting; métricas MAE, RMSE, MAPE y R ² ; data/processed/pronostico_ventas.csv; informe/img/pag08_pronostico.png.
Promedio ponderado de partes	20	80%	18.67	Cálculo: $(19 \times 0.20) + (19 \times 0.15) + (18 \times 0.16) + (19 \times 0.16) + (19 \times 0.16) + (18 \times 0.17) = 18.67$.
Rúbrica transversal	20	20%	19	Informe consolidado; datos sintéticos reproducibles con semilla 42; notebooks/00_generacion_datos.ipynb; prompts/registro_prompts.md; README.md; requirements.txt; repositorio Git; bitácora; reflexión ética y tabla de contribución.

PG estimado	20	100%	18.74	Fórmula: $PG = (18.67 \times 0.80) + (19 \times 0.20) = 18.74$.
--------------------	-----------	-------------	--------------	--

11.5. Lista de verificación detallada del cumplimiento

Criterio a verificar	Sí / Parcial / No	Evidencia	Brecha	Acción de mejora
Datos sintéticos reproducibles mediante semilla fija y documentados	Sí	notebooks/00_generacion_datos.ipynb, scripts de generación, sección 3 del informe y prompts/registro_prompts.md. Se utiliza semilla fija 42.	No se identifican brechas relevantes.	Mantener visibles en el notebook la semilla, los volúmenes generados y el resumen de calidad.
ETL corrige los siete problemas de calidad y reporta resultados antes/después	Sí	notebooks/01_datamart_etl.ipynb, scripts/validar_dataset.py, carpetas data/raw/ y data/processed/, secciones 3.4 y 3.5 del informe.	No se identifican brechas relevantes.	Verificar que las salidas del notebook permanezcan visibles en la versión final.
Esquema estrella correcto y relaciones válidas en Power BI	Sí	Sección 4 del informe, docs/diccionario_datos.md, informe/img/modelo_relaciones.png y powerbi/RetailBI.pbix.	No se identifican brechas relevantes.	Mantener disponible la captura del modelo y explicar el grano de la tabla de hechos.
Medidas DAX correctas y tablero con cuatro o más páginas	Sí	Sección 5.2 del informe, powerbi/RetailBI.pbix y capturas pag01_resumen.png a pag08_pronostico.png. El tablero contiene ocho páginas.	No se identifican brechas relevantes.	Revisar las medidas principales antes de la sustentación.

Storytelling con cinco o más insights accionables	Sí	Secciones 1.2 y 5.4 del informe: estacionalidad, productos estrella, concentración Pareto, diferencias por canal, segmento Bronce y mix de categorías.	No se identifican brechas relevantes.	Presentar cada insight junto con su recomendación de negocio.
Clasificación: comparación de modelos y métricas, incluido ROC-AUC	Sí	notebooks/03_clasificacion.ipynb y sección 6.3 del informe. Se comparan Regresión Logística, Árbol de Decisión y Random Forest.	No se identifican brechas relevantes.	Mantener visibles las métricas completas y explicar la selección del modelo.
Clasificación: interpretación y predicciones integradas en Power BI	Sí	data/processed/predicciones_abandono.csv, sección 6.5 y informe/img/pag05_abandono.png.	No se identifican brechas relevantes.	Explicar las acciones sugeridas para clientes de riesgo alto, medio y bajo.
Segmentación: valor de k justificado, perfilamiento y estrategias	Sí	notebooks/04_segmentacion.ipynb, secciones 7.1 a 7.4, segmentos_clientes.csv y pag06_segmentacion.png. Se utiliza RFM, método del codo, silueta y K-Means con k=4.	No se identifican brechas relevantes.	Revisar los perfiles de los cuatro segmentos antes de la exposición.
Asociación: reglas con soporte, confianza y lift interpretadas	Sí	notebooks/05_asociacion.ipynb, data/processed/reglas_asociacion.csv y sección 8.2. Se generaron 26 reglas.	No se identifican brechas relevantes.	Explicar conjuntamente soporte, confianza y lift.
Asociación: propuestas concretas de venta cruzada	Sí	Sección 8.4 del informe: combos promocionales, recomendaciones digitales, exhibición conjunta y campañas estacionales.	No se identifican brechas relevantes.	Incluir como ejemplo la regla Bebidas + Lácteos → Snacks y Dulces.

Regresión: validación temporal, métricas MAE, RMSE, MAPE y R ² , además del pronóstico	Sí	notebooks/06_regresion.ipynb, secciones 9.2 a 9.4, pronostico_ventas.csv y pag08_pronostico.png.	No se identifican brechas relevantes.	Presentar el pronóstico como apoyo operativo para inventario y campañas.
Notebooks ejecutan de principio a fin sin errores	Sí	Notebooks 00_generacion_datos.ipynb a 06_regresion.ipynb, con salidas, resultados y archivos derivados disponibles.	No se identifican brechas relevantes.	Realizar una última ejecución de verificación antes de la entrega.
Repositorio Git con commits de todos los integrantes	Sí	Repositorio GitHub del proyecto, historial de versiones y tabla de contribución del informe.	No se identifican brechas relevantes.	Mantener visibles los aportes de cada integrante en el historial del repositorio.
Registro de prompts del Anexo A e inclusión de la generación de datos del Anexo B	Sí	prompts/registro_prompts.md, secciones 10.2 y 10.3 del informe.	No se identifican brechas relevantes.	Verificar que el registro final conserve objetivo, herramienta, resultado y ajustes realizados.
Informe consolidado con la estructura indicada en el Anexo C	Sí	Informe consolidado con resumen ejecutivo, empresa, datos, seis componentes, ética, prompts, conclusiones, recomendaciones, contribución y autoevaluación.	No se identifican brechas relevantes.	Realizar la revisión final de índice, numeración, títulos, tablas y figuras.
Tabla de contribución por integrante	Sí	Sección 11.3 del informe con integrante, rol, actividades y porcentaje.	No se identifican brechas relevantes.	Confirmar la conformidad final de todos los integrantes.

Sustentación: cada integrante domina el conjunto de la solución	Sí	Presentación grupal preparada, distribución de diapositivas y guion de exposición por integrante.	La sustentación se realizará en la fecha programada.	Realizar un ensayo final y repasar posibles preguntas cruzadas del docente.
Uso ético de IA declarado y código comprendido	Sí	Secciones 10.1 y 10.2 del informe y prompts/registro_prompts.md. Se declara el uso de datos sintéticos y herramientas de IA.	No se identifican brechas relevantes.	Mantener preparadas explicaciones breves sobre el uso de IA, los modelos y las decisiones técnicas.